

Análisis Avanzado de Datos — Taller 03

Autores: Miguel Ángel Castelblanco García · Luis Gabriel Durán Fernández

Repositorio Taller 03

Problema 1 — Familia Exponencial (20 pts)

Una familia de distribuciones P_θ pertenece a la **familia exponencial** si su función de masa/densidad puede escribirse como:

$$p(x|\theta) = h(x) \cdot \exp(\eta(\theta) \cdot t(x) - a(\theta))$$

donde $h(x)$, $a(\theta)$ y $t(x)$ son funciones reales.

Demostraremos que **Bernoulli**, **Normal** y **Poisson** pertenecen a esta familia.

1.1 Distribución Bernoulli

Sea $X \sim \text{Bernoulli}(\pi)$, con $x \in \{0, 1\}$:

$$p(x|\pi) = \pi^x \cdot (1 - \pi)^{1-x}$$

Tomando logaritmo y exponenciando:

$$p(x|\pi) = \exp(\log(\pi^x \cdot (1 - \pi)^{1-x}))$$

$$p(x|\pi) = \exp(x \cdot \log(\pi) + (1 - x) \cdot \log(1 - \pi))$$

Agrupando términos

$$p(x|\pi) = \exp(x \cdot (\log(\pi) - \log(1 - \pi)) + \log(1 - \pi))$$

$$p(x|\pi) = \exp\left(x \cdot \log\left(\frac{\pi}{1 - \pi}\right) + \log(1 - \pi)\right)$$

Identificando los componentes de la familia exponencial:

Componente	Expresión
$h(x)$	1
$\eta(\theta)$	$\log\left(\frac{\pi}{1-\pi}\right)$ (logit)
$t(x)$	x
$a(\theta)$	$-\log(1 - \pi) = \log(1 + e^\eta)$

Por tanto, Bernoulli(π) pertenece a la familia exponencial.

Conexión con regresión logística: El parámetro natural $\eta = \log\left(\frac{\pi}{1-\pi}\right)$ es exactamente la función logit que se modela linealmente en la regresión logística: $\eta = \mathbf{x}^\top \boldsymbol{\beta}$.

1.2 Distribución Normal

Sea $X \sim \mathcal{N}(\mu, \sigma^2)$ con σ^2 conocido:

$$p(x|\mu) = \frac{1}{\sqrt{2 \cdot \pi \cdot \sigma^2}} \cdot \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right)$$

Expandiendo el cuadrado en el exponente:

$$p(x|\mu) = \frac{1}{\sqrt{2 \cdot \pi \cdot \sigma^2}} \cdot \exp\left(-\frac{x^2}{2\sigma^2} + \frac{2 \cdot \mu \cdot x}{2 \cdot \sigma^2} - \frac{\mu^2}{2\sigma^2}\right)$$

Agrupando términos:

$$p(x|\mu) = \frac{1}{\sqrt{2 \cdot \pi \cdot \sigma^2}} \cdot \exp\left(-\frac{x^2}{2\sigma^2}\right) \cdot \exp\left(\frac{\mu \cdot x}{\sigma^2} - \frac{\mu^2}{2\sigma^2}\right)$$

Identificando los componentes:

Componente	Expresión
$h(x)$	$\frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{x^2}{2\sigma^2}\right)$
$\eta(\theta)$	$\frac{\mu}{\sigma^2}$
$t(x)$	x
$a(\theta)$	$\frac{\mu^2}{2\sigma^2} = \frac{\eta^2 \sigma^2}{2}$

Por tanto, $\mathcal{N}(\mu, \sigma^2)$ pertenece a la familia exponencial.

Conexión con regresión lineal: El parámetro natural $\eta = \mu/\sigma^2$ es proporcional a la media condicional $E[Y|\mathbf{x}] = \mu = \mathbf{x}^\top \boldsymbol{\beta}$, función de enlace identidad.

1.3 Distribución Poisson

Sea $X \sim \text{Poisson}(\lambda)$, con $x \in \{0, 1, 2, \dots\}$:

$$p(x|\lambda) = \frac{\lambda^x \cdot e^{-\lambda}}{x!}$$

Aplicando propiedades de logaritmos

$$p(x|\lambda) = \frac{1}{x!} \cdot \exp(\log(\lambda^x)) \cdot \exp(-\lambda)$$

$$p(x|\lambda) = \frac{1}{x!} \cdot \exp(x \cdot \log(\lambda)) \cdot \exp(-\lambda)$$

$$p(x|\lambda) = \frac{1}{x!} \cdot \exp(x \cdot \log(\lambda) - \lambda)$$

Identificando los componentes:

Componente	Expresión
$h(x)$	$\frac{1}{x!}$
$\eta(\theta)$	$\log(\lambda)$ (log-link)
$t(x)$	x
$a(\theta)$	$\lambda = e^\eta$

Por tanto, $\text{Poisson}(\lambda)$ pertenece a la familia exponencial.

Conexión con regresión Poisson: El parámetro natural $\eta = \log(\lambda)$ es la función de enlace log: $\log E[Y|\mathbf{x}] = \mathbf{x}^\top \boldsymbol{\beta}$.

Problema 2 — Regresión Logística: Heart Disease UCI (50 pts)

Dataset: [Processed Cleveland Heart Disease](#)

Variables

#	Variable	Tipo	Descripción
1	age	Continua	Edad en años
2	sex	Binaria	1=hombre, 0=mujer
3	cp	Categórica	Tipo de dolor de pecho (1–4)
4	trestbps	Continua	Presión arterial en reposo (mmHg)
5	chol	Continua	Colesterol sérico (mg/dl)
6	fbs	Binaria	Glucemia en ayunas >120 mg/dl (1=sí, 0=no)
7	restecg	Categórica	Resultados ECG en reposo (0–2)
8	thalach	Continua	Frecuencia cardíaca máxima alcanzada
9	exang	Binaria	Angina inducida por ejercicio (1=sí, 0=no)
10	oldpeak	Continua	Depresión ST inducida por ejercicio
11	slope	Categórica	Pendiente del segmento ST máximo (1–3)
12	ca	Ordinal	N° de vasos principales coloreados (0–3)
13	thal	Categórica	Tipo de defecto talámico (3,6,7)
14	target	Respuesta	Diagnóstico (0=no enfermedad; 1–4 → binarizar a 1)

Información del DataSet

Dimensiones: 303 filas × 14 columnas

Valores faltantes por variable:


#	Variable	Cantidad
1	ca	4
2	thal	2

Los valores faltantes fueron imputados con su mediana.

Proporción de enfermedad: 0.459

Distribuciones Bivariadas

Se encontró que variables como `exang` , `ca` , `thal` y `cp` tienen categorías donde las poblaciones presentan mayores proporciones de individuos con valores positivos en la variable objetivo.



Tablas de Contingencia

Se identificaron dos inconvenientes concretos:

- `restecg = 1` tiene solo **4 observaciones** (1 sin enfermedad, 3 con enfermedad), lo que genera estimadores inestables con errores estándar muy grandes.
- `fbs` muestra distribuciones de la variable objetivo casi idénticas entre sus categorías ($\approx 50:50$), con una diferencia de solo **3.6 pp** (45.3% vs 48.9%).

restecg

restecg	target = 0	target = 1	Total
0	95	56	151
1	1	3	4
2	68	80	148
Total	164	139	303

Por otro lado ca y thal tienen categorías donde las combinaciones con valores negativos de la variable objetivo son pocas, aunque la categoría en general es representativa.

ca

ca	target = 0	target = 1	Total
0	133	47	180
1	21	44	65
2	7	31	38
3	3	17	20
Total	164	139	303

thal

thal	target = 0	target = 1	Total
3	130	38	168
6	6	12	18
7	28	89	117
Total	164	139	303

La variable `fbs` tiene distribuciones de la variable objetivo muy parecidas entre sus categorías (cerca de 50:50):

fbs

fbs	target = 0	target = 1	Total
0	141	117	258
1	23	22	45
Total	164	139	303

Modelo bivariado con `fbs`

Interpretación de $\hat{\beta}_0 = -0.1866$

$\hat{\beta}_0$ es el log-odds de tener enfermedad cardíaca cuando `fbs` = 0 (glucemia en ayunas normal):

$$\text{odds}(\text{enfermedad} \mid \text{fbs} = 0) = e^{\hat{\beta}_0} = e^{-0.1866} = 0.8298$$

Es decir, por cada paciente con glucemia normal que **tiene** enfermedad cardíaca hay 0.83 que **no la tienen** — una odds prácticamente de 1:1, consistente con $\hat{\pi}(\text{fbs} = 0) = 45.4\%$.

Interpretación de $\hat{\beta}_1 = 0.1421$ (OR = 1.1527)

$\hat{\beta}_1 = \log(\widehat{OR})$ cuantifica el cambio en log-odds al pasar de `fbs` = 0 a `fbs` = 1 :

$$\widehat{OR} = e^{0.1421} = 1.1527$$

Tener glucemia en ayunas elevada multiplica las odds de enfermedad cardíaca por **1.15** — un incremento del 15% que equivale a solo **3.5 pp** de diferencia en probabilidad (45.4% → 48.9%). `fbs` prácticamente **no discrimina** la presencia de enfermedad.

Significancia estadística

$$SE(\hat{\beta}_1) \approx \sqrt{\frac{1}{n_{11}} + \frac{1}{n_{10}} + \frac{1}{n_{01}} + \frac{1}{n_{00}}} = \sqrt{\frac{1}{22} + \frac{1}{23} + \frac{1}{117} + \frac{1}{141}} \approx 0.323$$
$$z_{\text{Wald}} = \frac{0.1421}{0.323} \approx 0.44 \quad \Rightarrow \quad p \approx 0.66$$

`fbs` **no es estadísticamente significativa** al nivel 5%. El IC 95% del OR incluye holgadamente el valor 1, lo que confirma que no hay evidencia de asociación entre glucemia en ayunas elevada

y la presencia de enfermedad cardíaca en esta muestra. Este resultado se mantiene en el modelo multivariado ($p \approx 0.50$ según el test de Wald).

Modelo Multivariado — Regresión Logística (GLM Binomial)

Estadístico	Valor
Observaciones	303
Log-verosimilitud	-97.431
Devianza	194.863
Pseudo R ² McFadden	0.5338
Pseudo R ² Cox-Snell	0.5212

Test de Wald — coeficientes e intervalos de confianza

Evaluamos la hipótesis nula de que la variable j no aporte información para la predicción de la variable respuesta:

$$z_j = \frac{\hat{\beta}_j}{SE(\hat{\beta}_j)} \xrightarrow{H_0} \mathcal{N}(0, 1)$$

	Coef	SE	z	p-valor	OR	IC 95% inf	IC 95% sup	Sig.
Intercept	-6.1119	2.8867	-2.1170	0.0342	0.0022	0.0000	0.6350	*
C(cp)[T.2]	1.1616	0.7633	1.5220	0.1281	3.1951	0.7157	14.2633	
C(cp)[T.3]	0.2401	0.6592	0.3640	0.7156	1.2714	0.3493	4.6276	
C(cp)[T.4]	2.1555	0.6635	3.2490	0.0012	8.6323	2.3517	31.6868	**
C(restecg) [T.1]	0.8340	2.4987	0.3340	0.7385	2.3026	0.0172	308.4197	
C(restecg) [T.2]	0.4737	0.3797	1.2480	0.2122	1.6060	0.7630	3.3804	

	Coef	SE	z	p-valor	OR	IC 95% inf	IC 95% sup	Sig.
C(slope) [T.2]	1.1544	0.4665	2.4750	0.0133	3.1720	1.2713	7.9143	*
C(slope) [T.3]	0.4961	0.9269	0.5350	0.5925	1.6422	0.2670	10.1029	
C(thal) [T.6]	-0.1045	0.7850	-0.1330	0.8941	0.9008	0.1934	4.1962	
C(thal) [T.7]	1.3085	0.4187	3.1250	0.0018	3.7008	1.6290	8.4076	**
age	-0.0148	0.0247	-0.6000	0.5487	0.9853	0.9386	1.0342	
sex	1.5723	0.5290	2.9720	0.0030	4.8175	1.7083	13.5859	**
trestbps	0.0242	0.0112	2.1550	0.0312	1.0245	1.0022	1.0473	*
chol	0.0044	0.0040	1.1060	0.2686	1.0044	0.9966	1.0124	
fbs	-0.3934	0.5788	-0.6800	0.4967	0.6748	0.2170	2.0981	
thalach	-0.0169	0.0111	-1.5260	0.1271	0.9832	0.9621	1.0048	
exang	0.7784	0.4370	1.7810	0.0749	2.1779	0.9249	5.1284	.
oldpeak	0.3676	0.2305	1.5950	0.1108	1.4442	0.9192	2.2691	
ca	1.2958	0.2774	4.6710	0.0000	3.6539	2.1215	6.2932	***

*** p<0.001 · ** p<0.01 · * p<0.05 · . p<0.10

Las variables estadísticamente significativas ($p < 0.05$) en el modelo multivariado son: el número de vasos coloreados por fluoroscopia (*ca*), el tipo de dolor de pecho severo (*cp* = 4), el defecto talámico reversible (*thal* = 7), el sexo (*sex*), la presión arterial en reposo (*trestbps*) y la pendiente plana del segmento ST (*slope* = 2).


Probabilidades predichas

Las distribuciones de probabilidad predicha están claramente separadas entre clases: los pacientes sin enfermedad se concentran en probabilidades bajas y los enfermos en probabilidades altas. El

AUC (≈ 0.936) y la exactitud ($\approx 87\%$) indican que el modelo describe bien la presencia de enfermedad cardíaca.

No obstante, existe una zona intermedia (probabilidades ≈ 0.5) con cierto solapamiento, donde el modelo es menos certero. Esto es esperable: el diagnóstico depende de factores no recogidos en estas 13 variables. En conjunto, el modelo es adecuado como herramienta de tamizaje del riesgo cardíaco.

Métrica	Valor
AUC-ROC	0.9356
Accuracy (umbral 0.5)	0.8713



Problema 3 — Comparación de modelos de predicción crediticia (20 pts)

El archivo `AAD-taller03.xlsx` contiene predicciones de dos modelos para 9.080 clientes y la variable observada de incumplimiento real al final del periodo.

Objetivo: Determinar cuál modelo tiene **mayor poder de predicción** con fundamento estadístico.

#	Variable	Tipo	Descripción
1	Incumplimiento	Binaria	Si hubo incumplimiento (0/1)
2	ScoreLogisticoA	Continua	Score modelo A — probabilidades en [0, 0.14]

#	Variable	Tipo	Descripción
3	ScoreLogisticoB	Continua	Score modelo B — orientación invertida , corregido con $1 - \text{score}$


ScoreLogisticoB venía orientado inversamente ($\text{AUC directo} = 0.3221 < 0.5$), lo que indica que un score alto correspondía a **menor** riesgo. Se corrigió con la transformación $1 - \text{scoreB}$, que invierte la orientación manteniendo los valores en $[0, 1]$.

Comparación de métricas

Métrica	Modelo A	Modelo B	Mejor
AUC ($\uparrow$ mejor)	0.6060	0.6779	B ✓
Brier Score ($\downarrow$ mejor)	0.4936	0.3451	B ✓
KS Statistic ($\uparrow$ mejor)	0.1915	0.2624	B ✓
p-valor KS	3.2438e-73	8.3937e-138	—

Curvas de calibración

Las curvas de calibración evalúan si las probabilidades predichas están alineadas con las frecuencias observadas. Un Brier Score menor indica mejor calibración.




Test de DeLong

	Modelo A	Modelo B
AUC	0.6060	0.6779
IC 95% (bootstrap)	[0.5947, 0.6170]	[0.6663, 0.6886]
Delta AUC (A – B)	-0.0718	—
z-statistic	-8.4336	—
p-valor DeLong	< 0.001	—

Conclusión ($\alpha = 0.05$): Se rechaza H_0 . **Modelo B** presenta significativamente mayor poder predictivo (AUC = 0.6779, $p < 0.001$).

Comparación visual



Conclusión

La diferencia de AUC (≈ 0.072 puntos) es estadísticamente significativa según el test de DeLong ($p < 0.001$). El **Modelo B discrimina mejor** entre clientes que incumplirán y los que no, independientemente del umbral de clasificación elegido. El Brier Score confirma que B también está mejor calibrado.

Problema 4 — Regresión Logística con Imputación EM (10 pts)

Repetir el Problema 2 usando **algoritmo EM (Expectation-Maximization)** para imputar los datos faltantes en lugar de la mediana.

En Python, `sklearn.impute.IterativeImputer` implementa un algoritmo tipo MICE que bajo distribuciones normales converge al estimador EM. Es la alternativa práctica estándar al EM puro para datos mixtos.


Fundamento teórico del EM para datos faltantes

Bajo el supuesto MAR (*Missing At Random*), el algoritmo EM itera entre:


- **E-step:** Calcular $Q(\theta|\theta^{(t)}) = E[\log p(X_{obs}, X_{mis}|\theta) | X_{obs}, \theta^{(t)}]$
- **M-step:** Maximizar Q respecto a θ : $\theta^{(t+1)} = \arg \max_{\theta} Q(\theta|\theta^{(t)})$

Para datos normales multivariados, el EM produce imputaciones óptimas en varianza.

Comparación de imputaciones



Distribuciones bivariadas (imputación EM)




Comparación Wald: Mediana vs EM

La siguiente tabla muestra los coeficientes y significancia de cada variable bajo ambos métodos de imputación, permitiendo identificar si alguna variable cambia de significancia.

Los resultados son prácticamente idénticos dado que solo el 2% de los valores (6/303) eran faltantes.

Comparación final: Mediana vs EM

Métrica	Mediana	EM	Mejor
AUC-ROC (↑)	0.9356	0.9359	EM
Brier Score (↓)	0.0975	0.0976	Mediana



Conclusión

La imputación EM y la imputación por mediana producen resultados prácticamente idénticos. Esto es esperable: solo 6 de 303 valores (2%) eran faltantes, por lo que el método de imputación tiene impacto mínimo sobre el modelo.

Las variables significativas al 5% son las mismas en ambos enfoques. El AUC y el Brier Score difieren en menos de 0.001 puntos.

Desde una perspectiva estadística:

- La **mediana** es válida bajo **MCAR** (*Missing Completely At Random*): los faltantes no dependen de ninguna variable.
- El **EM** es válido bajo **MAR** (*Missing At Random*): los faltantes pueden depender de variables observadas. Es el supuesto más razonable en la práctica y hace al EM preferible cuando la proporción de faltantes es mayor.

Anexos

Tablas de contingencia completas

sex

sex	target = 0	target = 1	Total
0	72	25	97
1	92	114	206
Total	164	139	303

cp

cp	target = 0	target = 1	Total
1	16	7	23
2	41	9	50
3	68	18	86
4	39	105	144
Total	164	139	303

fb

fb	target = 0	target = 1	Total
0	141	117	258
1	23	22	45
Total	164	139	303

restecg

restecg	target = 0	target = 1	Total
0	95	56	151
1	1	3	4
2	68	80	148
Total	164	139	303

exang

exang	target = 0	target = 1	Total
0	141	63	204
1	23	76	99
Total	164	139	303

slope

slope	target = 0	target = 1	Total
1	106	36	142

slope	target = 0	target = 1	Total
2	49	91	140
3	9	12	21
Total	164	139	303

ca

ca	target = 0	target = 1	Total
0	133	47	180
1	21	44	65
2	7	31	38
3	3	17	20
Total	164	139	303

thal

thal	target = 0	target = 1	Total
3	130	38	168
6	6	12	18
7	28	89	117
Total	164	139	303